

Reporte detallado — Clustering de empresas (Capa 1 y Capa 2)

Fecha: 2026-05-09

Proyecto: Desarrollo_clustering_maestria

Nota de consistencia: las cifras de este reporte se calculan/leen desde los CSV en 04_modeling/outputs/ y 05_evaluation/outputs/. Algunas figuras exportadas pueden mostrar N o líneas de “tasa base” de una corrida previa; usa las tablas como referencia numérica.

1) Resumen ejecutivo

Este reporte documenta los resultados del clustering en dos niveles:

- **Capa 1 (N=157):** segmentación basada en variables tipo “registro/estructura/operación” (por ejemplo, tipo de sociedad, obligaciones, sector macro, región, estado activo, fuente).
- **Capa 2 (N=87):** segmentación basada en variables con mayor contenido financiero/tamaño (por ejemplo, ingresos/activos/empleados en escala log, antigüedad, liquidez, margen, segmento).

Hallazgos principales:

- **Capa 1 (K=4) separa fuertemente la tasa FPA:**
 - Clústeres con tasas altas (~48% y ~50%) y clústeres con tasas bajas (~10.5% y ~17.1%).
 - **Capa 2 (K=2) no separa tanto la tasa FPA:** ambos segmentos quedan cerca de la tasa base (~42.5%).
 - **Cobertura SCVS por clúster (Capa 1):** un clúster (C2) tiene **cobertura financiera 0%**, lo que limita análisis financieros/externos para ese segmento.
 - **Consistencia entre capas (ARI):** concordancia **moderada** (ARI ~0.38 para C1 K=4 vs C2 K=2 en el subconjunto común).
-

2) Artefactos revisados (fuentes del reporte)

Modelado (Capa 1 y Capa 2)

- Asignaciones:
 - clusters_capa1.csv
 - clusters_capa2.csv
- Perfiles por clúster:
 - perfil_clusters_capa1.csv
 - perfil_clusters_capa2.csv

- Comparación entre capas:
 - `comparacion_capas_best_k.csv`
 - `comparacion_capas_same_k.csv`
- Sensibilidad (Capa 2 con K=4):
 - `clusters_capa2_k4_sensibilidad.csv`
 - `perfil_clusters_capa2_k4.csv`

Evaluación

- Métricas internas:
 - `metricas_evaluacion_capa1.csv`
 - `metricas_evaluacion_capa1_ward.csv`
 - `metricas_evaluacion_capa2.csv`
- Validación externa / consistencia:
 - `cobertura_financiera_por_cluster.csv`
 - `tabla_concordancia_ari.csv`
- Figuras exportadas:
 - `fig_seleccion_k_kmeans.png`
 - `fig_silhouette_muestras_c1.png`
 - `fig_pca_capa1.png`
 - `fig_tsne_capa1.png`
 - `fig_pca_capa2.png`
 - `fig_tasa_fpa_por_cluster.png`
 - `fig_cobertura_vs_fpa.png`

3) Universo y tasas base (calculadas desde asignaciones)

- **Capa 1:** N = 157, clientes FPA = 51 → **tasa base = 32.5%**
- **Capa 2:** N = 87, clientes FPA = 37 → **tasa base = 42.5%**
- **Comunes (intersección entre Capa 1 y Capa 2):** N = 87, clientes FPA = 37 → **tasa base = 42.5%**

Interpretación rápida:

- Capa 2 trabaja sobre un **subuniverso** con información adicional (financiera/tamaño). Por eso su tasa base puede diferir respecto al universo de Capa 1.

4) Metodología — Variables de entrada por capa

El pipeline de preparación parte de dos fuentes principales (LEADS y HORAS) enriquecidas con datos de la Superintendencia de Compañías (SCVS) y el SRI. Tras el matching, normalización y limpieza, se construyen dos matrices de features:

4.1 Capa 1 — Variables de estructura y registro (N=157)

Capa de **mayor cobertura**: usa únicamente información registral/tributaria disponible para casi todo el universo.

Variable	Tipo	Descripción
tipo_sociedad	Binaria (0/1)	1 = sociedad anónima/compañía; 0 = persona natural
obligado_contabilidad	Binaria	Obligación de llevar contabilidad (SRI)
es_agente_retencion	Binaria	Calificado como agente de retención (SRI)
es_contribuyente_especial	Binaria	Calificado como contribuyente especial (SRI)
estado_activo	Binaria	Empresa activa en el registro (SCVS/SRI)
antiguedad_anos	Continua (estandarizada)	Años desde constitución hasta fecha de análisis
sector_ciiu_macro_*	One-hot	Sector económico macro (C=manufactura, G=comercio)
region_*	One-hot	Región geográfica (Guayas, Pichincha, Resto)

Fuente: matriz_capa1.csv / features_capa1.csv

4.2 Capa 2 — Variables de tamaño y finanzas (N=87)

Capa de **mayor profundidad**: requiere que la empresa tenga estados financieros disponibles en SCVS. Incluye todo lo de Capa 1 más variables financieras/de tamaño derivadas de los estados financieros.

Variable	Tipo	Descripción
tipo_sociedad	Binaria	Igual que Capa 1
obligado_contabilidad	Binaria	Igual que Capa 1
es_agente_retencion	Binaria	Igual que Capa 1
es_contribuyente_especial	Binaria	Igual que Capa 1
estado_activo	Binaria	Igual que Capa 1
antiguedad_anos	Continua (estandarizada)	Igual que Capa 1
log_empleados	Continua (log+estand.)	Logaritmo del número de empleados
log_ingresos	Continua (log+estand.)	Logaritmo de los ingresos totales (SCVS)
log_activos	Continua (log+estand.)	Logaritmo de los activos totales (SCVS)
segmento	Continua (estandarizada)	Segmento SCVS (1=micro, 2=pequeña, 3=mediana)
liquidez_corriente	Continua (estandarizada)	Activo corriente / pasivo corriente
margen_operacional	Continua (estandarizada)	Resultado operacional / ingresos
sector_ciiu_macro_*	One-hot	Igual que Capa 1
region_*	One-hot	Igual que Capa 1

Fuente: matriz_capa2.csv / features_capa2.csv

4.3 Preprocesamiento aplicado

- Variables continuas: estandarizadas (media=0, std=1) antes del clustering.

- Variables binarias: se usan directamente (0/1).
- Variables categóricas (sector, región): codificadas como One-Hot.
- Variables financieras (empleados, ingresos, activos): transformadas a log antes de estandarizar, para reducir el efecto de outliers extremos.
- El año de los estados financieros (Capa 2) es el más reciente disponible por empresa.

4.4 Algoritmo y configuración

- **Algoritmo principal:** K-Means (inicialización k-means++, 100 inicializaciones, semilla fija).
- **Algoritmo comparativo:** Ward (clustering jerárquico), usado para validar robustez del K elegido.
- **Criterio de K:** combinación del método del codo (inercia) + silhouette promedio + restricción práctica de no generar clústeres con $n < 10$.

5) Selección de K y desempeño interno

5.1 Capa 1 — Comparación KMeans vs Ward

- KMeans tiende a dar mejores resultados de **silhouette** que Ward para los mismos K, según:
 - `metricas_evaluacion_capa1.csv`
 - `metricas_evaluacion_capa1_ward.csv`

Extracto (Capa 1):

Método	K	Silhouette	Davies-Bouldin	Tamaño min/max
KMeans	2	0.266	1.487	55 / 102
KMeans	4	0.213	1.613	34 / 50
Ward	2	0.257	1.506	51 / 106
Ward	4	0.185	1.731	28 / 51

Decisión práctica recomendada (Capa 1): K=4 (KMeans) por:

- Granularidad útil (4 segmentos interpretables).
- Tamaños balanceados (34–50 por clúster) evitando micro-clústeres.


5.2 Capa 2 — Robustez vs "micro-clústeres"

En Capa 2, silhouette aumenta cuando K crece (hasta K=4), pero aparecen clústeres muy pequeños:

K (KMeans)	Silhouette	Tamaño min/max	Comentario
2	0.386	35 / 52	Segmentación robusta y estable
3	0.399	2 / 52	Aparecen micro-clústeres
4	0.409	1 / 50	Riesgo alto de clúster “outlier”

Decisión práctica recomendada (Capa 2): K=2 (KMeans) para mantener estabilidad y evitar que outliers definan clústeres de tamaño 1.

Figura — Selección de K (KMeans)



6) Resultados — Capa 1 (K=4)

6.1 Resumen por clúster (Capa 1)

Tasa base Capa 1: **32.5%**

Clúster	Segmento	n	Tasa FPA	Δ vs base (pp)	Cobertura SCVS
C0	Sociedades jóvenes de alta afinidad FPA	50	48.0%	+15.52	82.0%
C1	Grandes corporativos maduros establecidos	34	50.0%	+17.52	64.7%
C2	Empresas comerciales de Guayas	38	10.5%	-21.96	0.0%
C3	Personas naturales del resto del país	35	17.1%	-15.34	68.6%

Fuente:


- Asignaciones: `clusters_capa1.csv`
- Cobertura: `cobertura_financiera_por_cluster.csv`

6.2 Interpretación cualitativa (Capa 1)

Basado en `perfil_clusters_capa1.csv`:


- **C0 — “Alta afinidad FPA” (48%)**
 - Moda región: **Pichincha**; sector macro: **C**; fuente modal: **LEADS**.
 - Alta proporción de obligaciones/atributos (p. ej., agente de retención ~82%, contribuyente especial ~86%, activo ~88%).
 - **Uso sugerido:** priorizar campañas/seguimiento comercial y propuestas de valor FPA.
- **C1 — “Grandes corporativos maduros” (50%)**
 - Moda región: **Pichincha**; fuente modal: **HORAS**.
 - Aunque el segmento sugiere “corporativos”, en los indicadores tributarios aparece menor proporción de “agente de retención” vs C0.
 - **Uso sugerido:** cuenta clave / estrategia enterprise, con enfoques de retención y expansión.
- **C2 — “Comerciales de Guayas” (10.5%)**
 - **Cobertura SCVS = 0%**, lo cual indica que para este segmento no se dispone de estados/financieros SCVS en el universo actual.
 - Sector macro modal: **G**; región modal: **Resto** (según perfil).
 - **Uso sugerido:** es el segmento “baja afinidad” y con baja trazabilidad financiera; requiere enriquecimiento adicional (otras fuentes) antes de decisiones basadas en finanzas.
- **C3 — “Personas naturales resto del país” (17.1%)**
 - Región modal: **Guayas**; sector macro: **G**; fuente modal: **LEADS**.
 - **Uso sugerido:** segmento de afinidad baja-media; enfoque más selectivo y con mayor filtrado previo.


Figura — Silhouette por muestra (Capa 1)



Figuras — Embeddings (PCA / t-SNE) para visualización

PCA/t-SNE se usan aquí como **visualización** (no como modelo).





7) Resultados — Capa 2 (K=2)

7.1 Resumen por clúster (Capa 2)

Tasa base Capa 2: **42.5%**

Clúster	Segmento	n	Tasa FPA	Δ vs base (pp)
C0	Empresas pequeñas y recientes	35	42.9%	+0.33
C1	Empresas medianas-grandes consolidadas	52	42.3%	-0.22

Fuente:

- Asignaciones: `clusters_capa2.csv`
- Perfiles: `perfil_clusters_capa2.csv`

7.2 Interpretación cualitativa (Capa 2)

Basado en `perfil_clusters_capa2.csv`:


- **C0 — Pequeñas y recientes**
 - Mediana antigüedad ~8 años.
 - Métricas en escala log (empleados/activos/ingresos) sugieren menor tamaño relativo.

- **C1 — Medianas-grandes consolidadas**
 - Mediana antigüedad ~36.5 años.
 - Escalas log más altas (empleados/ingresos/activos), consistente con mayor tamaño.

Conclusión operativa:

- Esta capa separa bien por **tamaño/madurez**, pero **no separa de forma marcada** por tasa FPA (ambos segmentos quedan cerca de la tasa base).

Figura — PCA 2D (Capa 2)



Sensibilidad K=4 (Capa 2)

El análisis K=4 crea clústeres muy pequeños (n=1-2), típicamente outliers (por ejemplo, liquidez extremadamente alta).


- Perfil K=4: `perfil_clusters_capa2_k4.csv`

8) Validación externa: Cobertura financiera (SCVS) vs afinidad FPA

La cobertura financiera por clúster (Capa 1) muestra un patrón relevante:

- C0 (82%), C1 (64.7%) y C3 (68.6%) tienen cobertura SCVS moderada/alta.
- **C2 tiene cobertura 0%**, lo que limita contrastes financieros y puede sesgar análisis “financieros” si se mezclan universos.

Figura:



9) Consistencia entre capas (ARI)

En el subconjunto común (N=87), la concordancia entre particiones es **moderada**:

Comparación	N comunes	ARI
C1 K=4 vs C2 K=2	87	0.376
C1 K=4 vs C2 K=4	87	0.324

Fuente: `tabla_concordancia_ari.csv`

Interpretación:

- Las capas capturan criterios distintos (Capa 1: “estructura/operación”; Capa 2: “tamaño/finanzas”), por lo que no se espera ARI alto.

10) Recomendaciones de uso (operativas)

1) Priorización comercial (FPA):

- En Capa 1, priorizar C0 y C1 por tasas FPA muy superiores a la base.
- Tratar C2 como segmento de baja afinidad; evitar esfuerzos intensivos salvo que haya señales adicionales.

2) Estrategia de datos:

- Para C2 (cobertura SCVS 0%), considerar enriquecer con otras fuentes o validar si su naturaleza (tipo de contribuyente/actividad) explica la ausencia en SCVS.

3) Uso combinado de capas:

- Capa 1 sirve mejor para “afinidad FPA” (separación clara).
 - Capa 2 sirve mejor para “tamaño/madurez” (segmentación empresarial) y puede complementar el perfilado, aunque no discrimine FPA por sí sola.
-

11) Cómo regenerar el reporte (reproducibilidad)

- Re-generar outputs y figuras ejecutando:
 - 04_modeling/01_clustering.ipynb
 - 05_evaluation/01_evaluacion_clustering.ipynb
 - Luego actualizar este reporte si cambian los CSV/figuras.
-

Anexo A — Figura: Tasa de clientes FPA por clúster

